lista 4

Marta Hałas

2025-06-06

Spis treści

1 Zadanie 1 **1**

1.1 a) Zaawansowane metody klasyfikacji . . . 1

1.1.1 Jakie dane będą analizowane? . . . 1

1.1.2 Cel i opis analizy . . . 4

1.2 b) Rodziny klasyfikatorów, uczenie zespołowe - zastosowanie algorytmów . . . 4

1.2.1 Metoda bagging . . . 5

1.2.2 Metoda random forest . . . 8

1.2.3 Ranking cech - wykres VIM . . . 12

1.2.4 Wnioski . . . 14

1.3 c) Metoda wektorów nośnych (SVM) . . . 16

1.3.1 Klasyfikatory dla funkcji jądrowych - porównanie skuteczności . . . 16

1.3.2 "Dostrojenie" parametrów γ i C dla jądra radialnego . . . 19

1.3.3 Wnioski . . . 20

1.4 d) Wnioski - porównanie skuteczności metod na podstawie podpunktu b, c . . . 20

1 Zadanie 1

1.1 a) Zaawansowane metody klasyfikacji

1.1.1 Jakie dane będą analizowane?

Dane: PimaIndiansDiabetes2

Do porównania metod klasyfikacji wybrałam zbiór danych PimaIndiansDiabetes2.

Rozmiar danych: liczba wierszy to 768 , liczba kolumn to 9.

Typy poszczególnych cech:

```
##          names.d. sapply.d..class.
## pregnant pregnant          numeric
## glucose   glucose          numeric
## pressure pressure          numeric
## triceps   triceps          numeric
## insulin   insulin          numeric
## mass         mass          numeric
## pedigree pedigree          numeric
## age           age          numeric
## diabetes diabetes           factor
```

Wszystkie zmienne mają prawidłowo przypisane typy. Zmienna zawierająca etykietki klas jest zmienną typu factor. Reszta zmiennych jest typu numeric, co jest zgodne z intuicją.

Opis zmiennych

- pregnant - liczba przebytych ciąż
- glucose - stężenie glukozy w osoczu
- pressure - ciśnienie rozkurczowe (mm Hg)
- triceps - grubość fałdu skórnego tricepsa (mm)
- insulin - insulina w surowicy 2-godzinna (mu U/ml)
- mass - maksymalny indeks ciała
- pedigree - funkcja rodowodu cukrzycy
- age - wiek (lata)
- diabetes - zmienna klasowa (test na cukrzycę)

Zbiór danych PimaIndiansDiabetes2 posiada dwie klasy: 0 - brak cukrzycy 1 - obecność cukrzycy

Za informacje o przynależności obkietu do konkretnej klasy odpowiada zmienna ***diabetes*** i zawiera wartości "pos" (positive – cukrzyca) oraz "neg" (negative – brak cukrzycy)

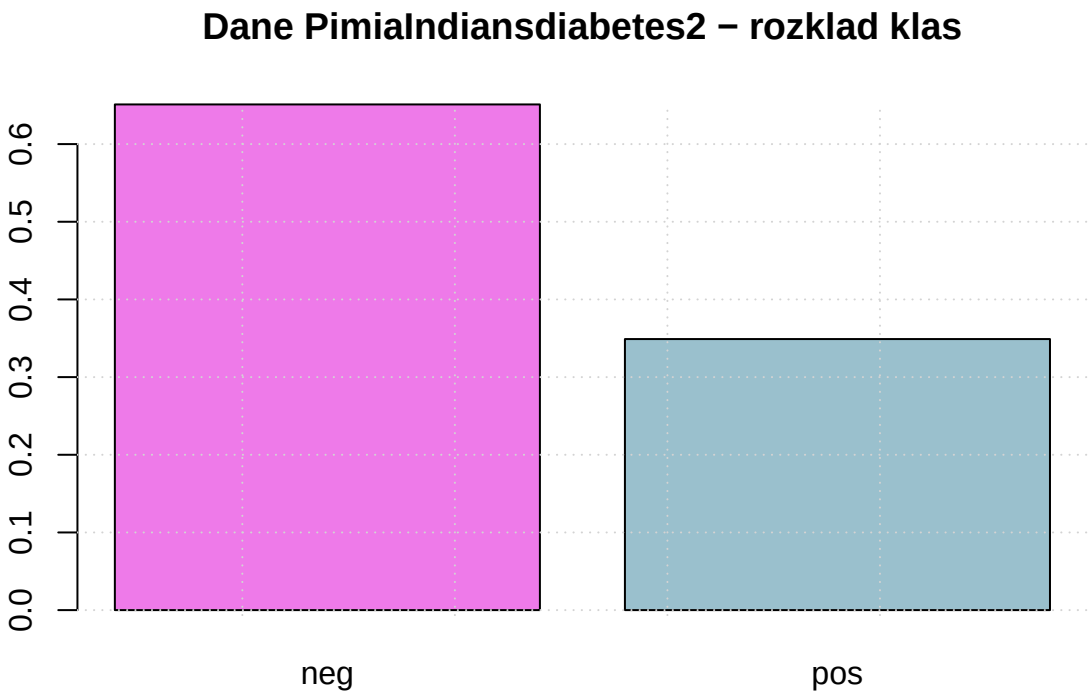

Zauważamy przewagę w liczebności klasy neg - brak cukrzycy.

Brakujące obserwacje - nietypowe własności danych

Liczba NA - brakujących obserwacji - Liczba braków danych kodowanych za pomocą "NA" wynosi 652

	Ilość brakujących danych
pregnant	0
glucose	5
pressure	35
triceps	227
insulin	374
mass	11
pedigree	0
age	0
diabetes	0

Brakujące dane są tylko dla zmiennych typu numeric.

Do dalszej analizy potrzebne jest pominięcie wartości NA lub zastąpienie ich wartościami liczbowymi. Usunięcie (czyli pominięcie) wierszy zawierających NA, powoduje utratę wielu obserwacji. Zatem zastosujemy metodę "KNN" - dla 5 sąsiadów.

1.1.2 Cel i opis analizy

Celem analizy jest porównanie różnych metod klasyfikacji:

- Bagging
- Randomforest
- SVM

Przypatrując się równocześnie wpływowi doboru różnych parametrów badanych metod.

W pierwszej części analizować będziemy klasyczne drzewa klasyfikacyjne, metodę bagging oraz randomforest w zależności od liczby drzew.

W drugiej części przypatrzymy się metodzie wektorów nośnych SVM. Użyjemy jądra liniowego, jądra wielomianowego oraz jądra radialnego w zależności od parametru cost.

Porównamy również wpływ parametru degree na jądro wielomianowe oraz parametru gamma w jądrze radialnym.

Znajdziemy również proponowane optymalne parametry cost i gamma dla jądra radialnego i porównamy błąd klasyfikacyjny otrzymany dla nich względem wcześniej dobranych przez nas parametrów.

W ostatnim etapie będzie podsumowanie oraz wysunięcie odpowiednich wniosków.

1.2 b) Rodziny klasyfikatorów, uczenie zespołowe - zastosowanie algorytmów

Drzewo klasyfikacyjne

Drzewo klasyfikacyjne używane było również na poprzedniej liście. Poniżej znajdziemy wartości błędów klasyfikacyjnych uzyskanych przy zastosowaniu różnych schematów.

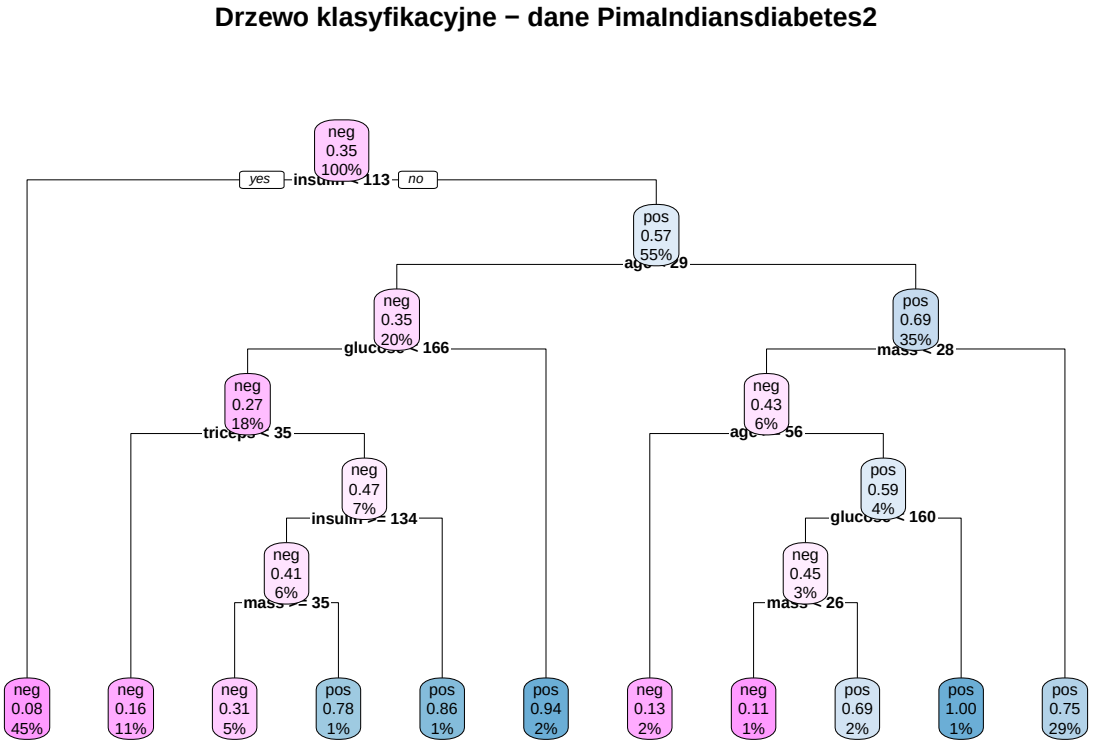

Schemat "623+"

Błąd klasyfikacji pojedynczego drzewa jest na poziomie 20.7%

Schemat bootstrap

Błąd klasyfikacji pojedynczego drzewa jest na poziomie 23.53%

Schemat cross-validation

Błąd klasyfikacji pojedynczego drzewa jest na poziomie 20.31%

1.2.1 Metoda bagging

Metoda bagging

Bagging to metoda łączenia wielu modeli trenowanych na losowych podzbiorach danych, aby zwiększyć dokładność i zmniejszyć przeuczenie.

Poniżej za pomocą tej metody i różnych schematów oraz różnej liczby drzew wyznaczam błąd klasyfikacyjny.

schemat 632+

Tablica 2: Błąd klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Błąd klasyfikacji (%)
1	20.31
5	17.80
10	17.09
20	16.07
30	16.31
40	16.44
50	16.05
100	16.02

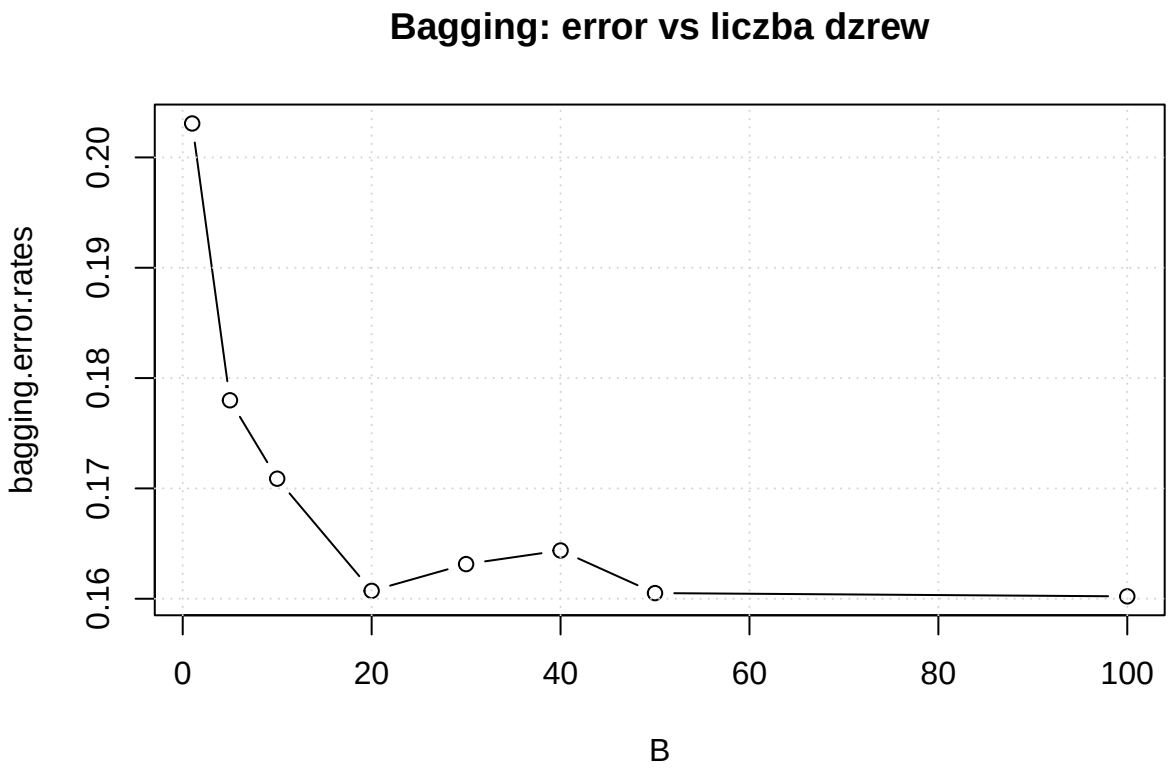

Najmniejszy błąd klasyfikacji dla 100 drzew.

schemat bootstrap

Tablica 3: Błąd klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Błąd klasyfikacji (%)
1	25.82
5	22.28
10	22.09
20	21.18
30	21.21
40	21.30
50	21.20
100	20.74

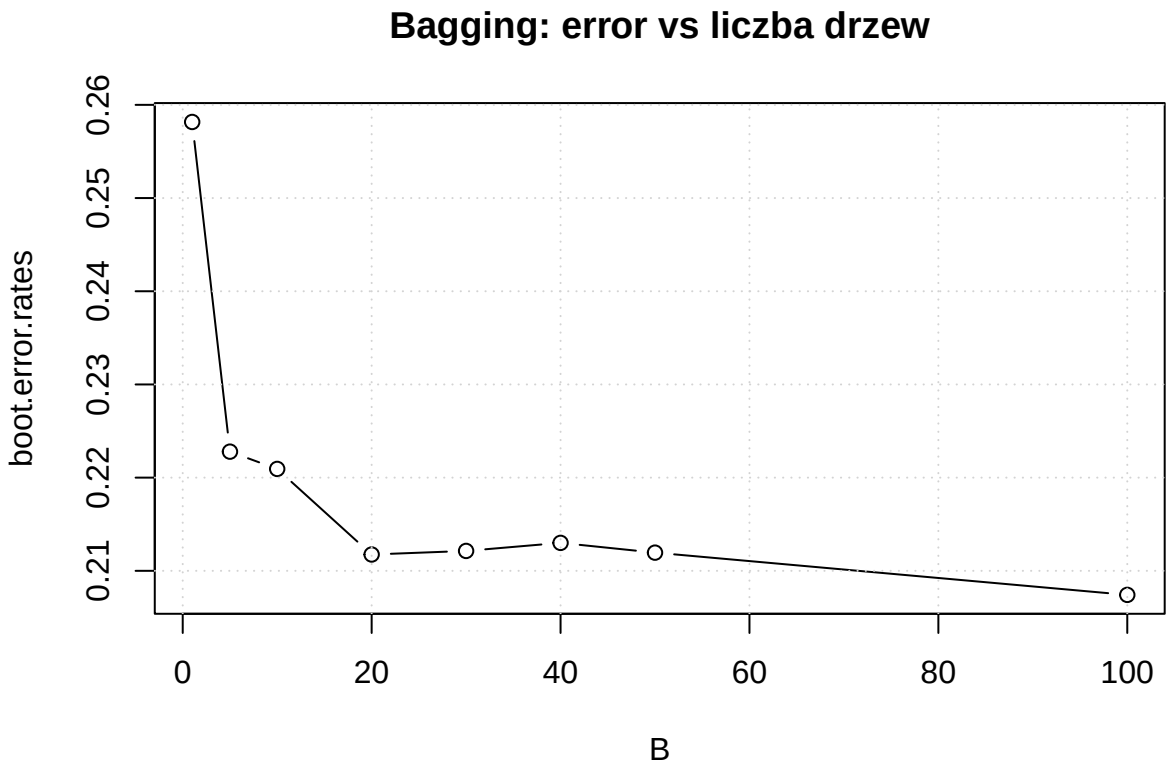

Najmniejszy błąd klasyfikacji dla 100 drzew.

Schemat cross-validation

Tablica 4: Błąd klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Błąd klasyfikacji (%)
1	23.70
5	18.88
10	21.88
20	18.88
30	20.96
40	19.14
50	20.05
100	19.79

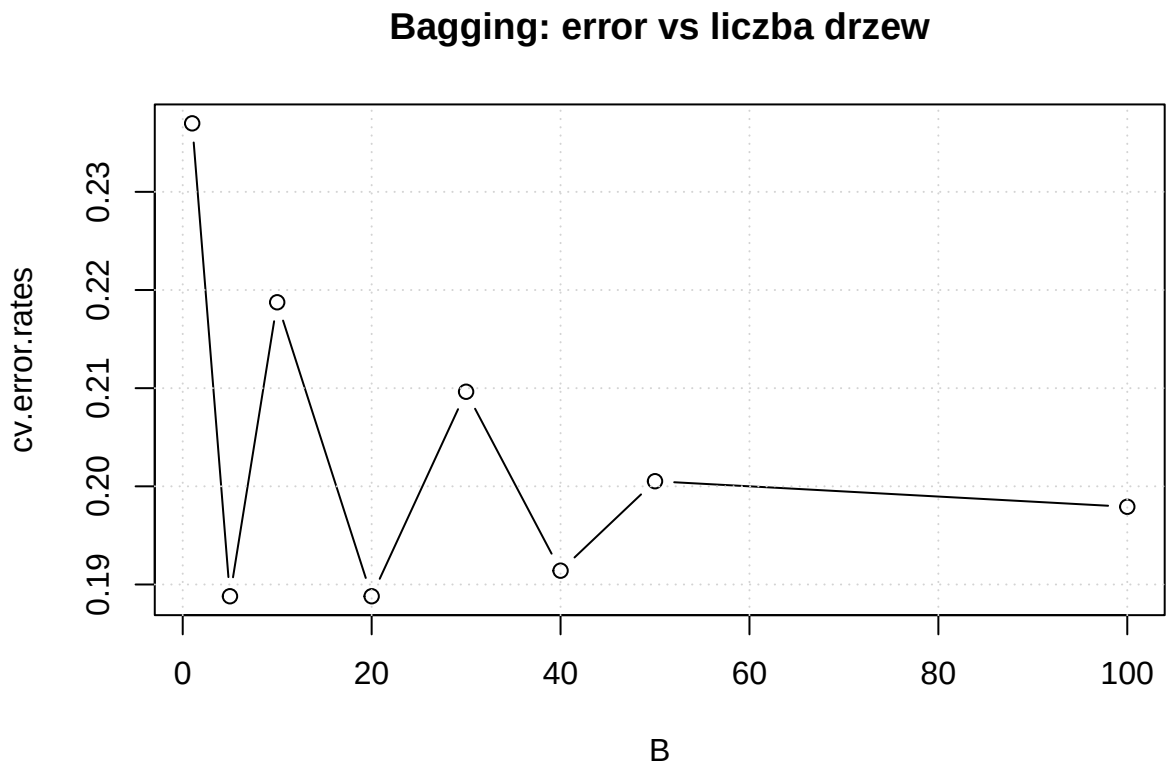

Najmniejszy błąd klasyfikacji dla 5 drzew, niewielka różnica w porówaniu z błędem dla 100 dzrew.

Wnioski

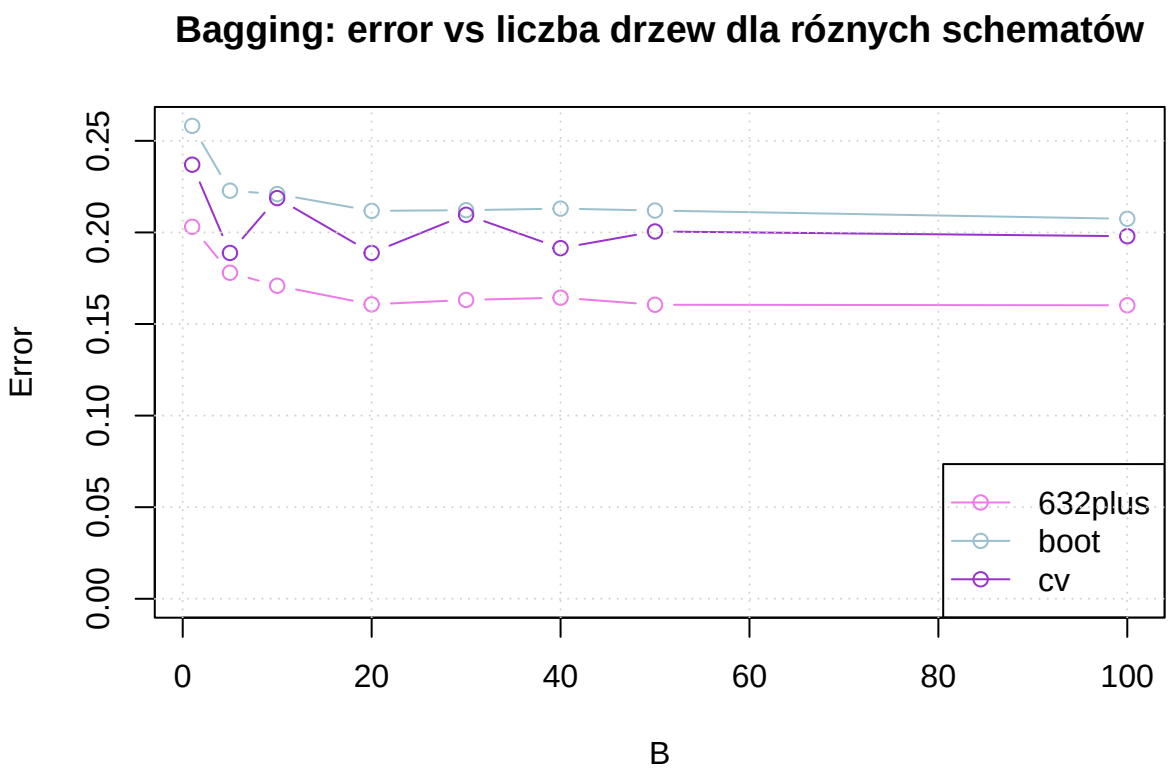

Najmniejsze błędy klasyfikacyjne otrzymaliśmy dla schematu 632+, największe wskazała metoda bootstrap.

1.2.2 Metoda random forest

Random Forest to zbiór losowo budowanych drzew decyzyjnych, których wspólna decyzja daje dokładniejszy i stabilniejszy model, a jakość modelu jest oceniana na danych nieużytych do trenowania danego drzewa (OOB) – bez potrzeby oddzielnego zbioru walidacyjnego.

Poniżej za pomocą tej metody i różnych schematów oraz różnej liczby drzew wyznaczam błąd klasyfikacyjny.

Metoda forest

zbiór uczący i testowy

dla ntree=1

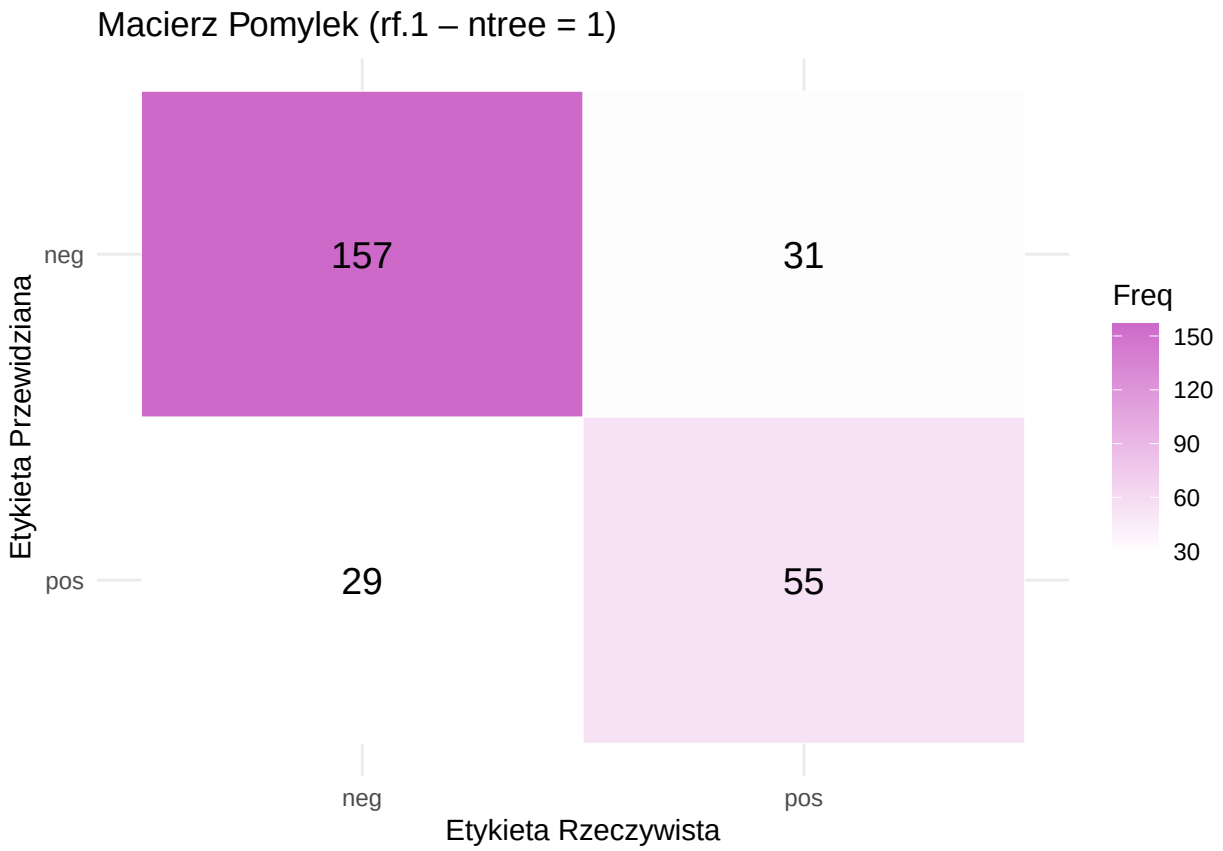

Estymacja OOB błędu wynosi 22.06%

dla ntree=100

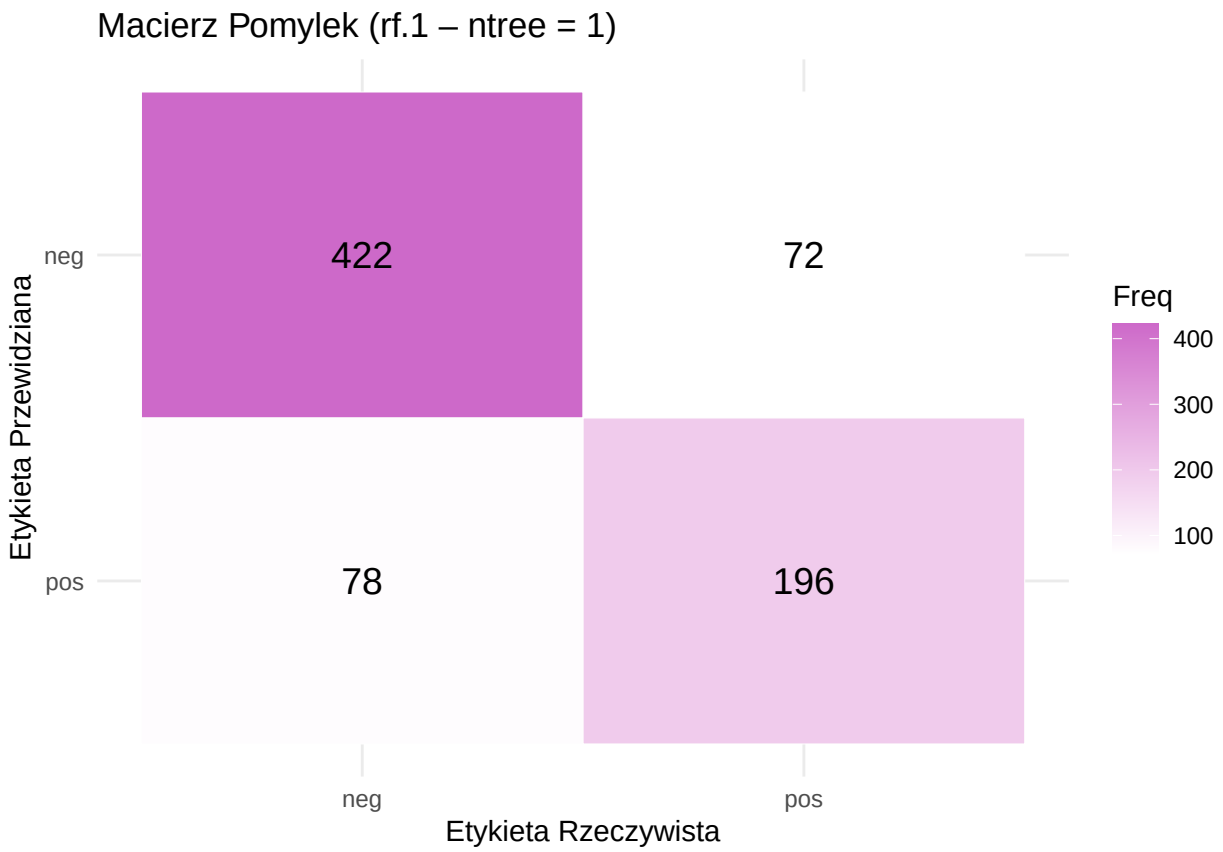

Estymacja OOB błędu wynosi 19.53%

Widzimy pomniejszenie błedu klasyfikacji o 3 punkty procentowe.

schemat 632+

Tablica 5: Błąd klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Błąd klasyfikacji (%)
1	23.60
5	18.06
10	16.30
20	15.38
30	14.68
40	14.85
50	14.70
100	14.24

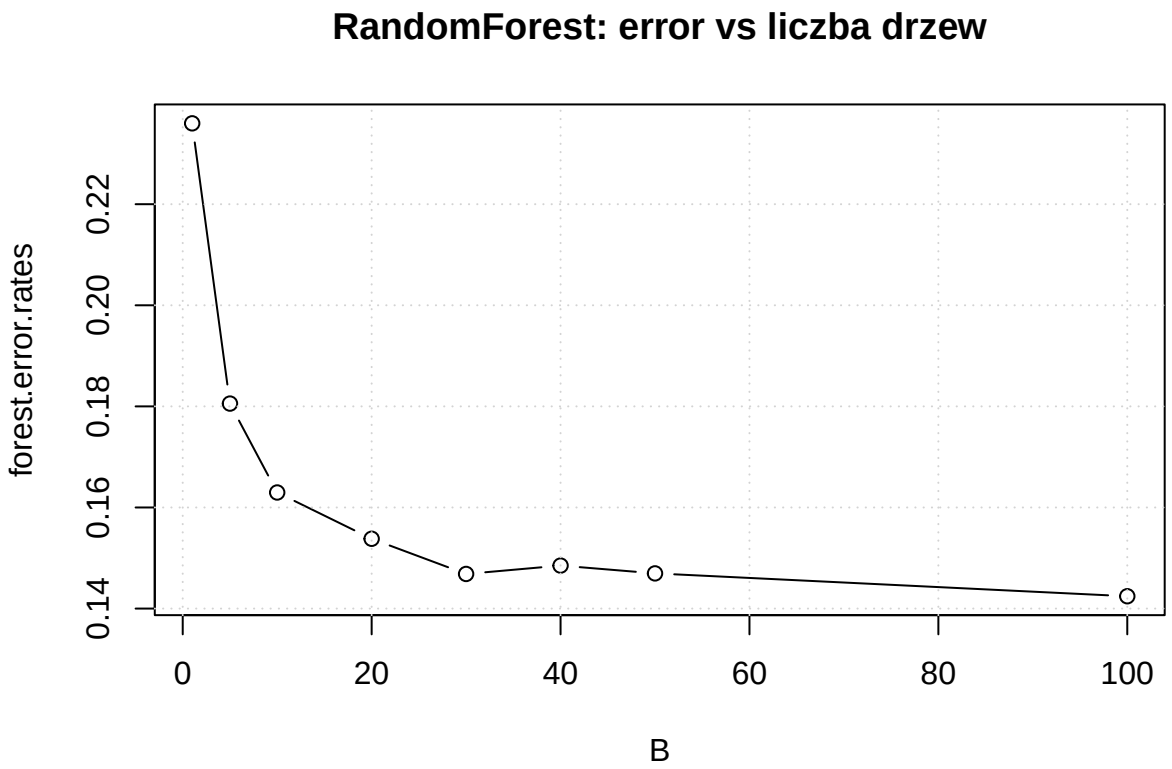

Najmniejszy błąd klasyfikacji dla od 30 do 100 drzew na podobnym poziomie 14%. Duża różnica w porównaniu z błędem dla 1 drzewa 32%.

schemat bootstrap

Tablica 6: Błąd klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Błąd klasyfikacji (%)
1	28.65
5	23.29
10	21.09
20	20.44
30	19.85
40	20.41
50	19.45
100	20.11

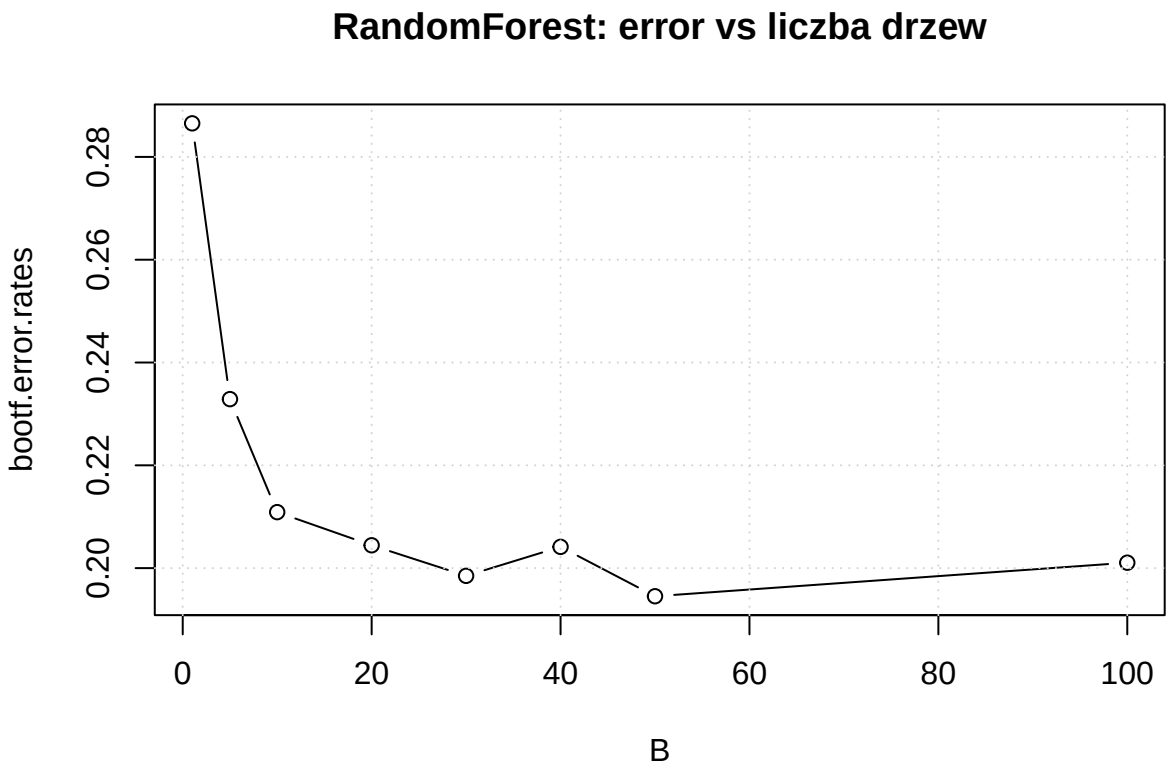

Najmniejszy błąd klasyfikacji dla 50 i 30 drzew. Niewielka różnica z tymi dla 40,100 i 20 drzew. .
Schemat cross-validation

Tablica 7: Błąd klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Błąd klasyfikacji (%)
1	26.43
5	22.79
10	19.92
20	19.53
30	19.14
40	19.27
50	20.31
100	19.27

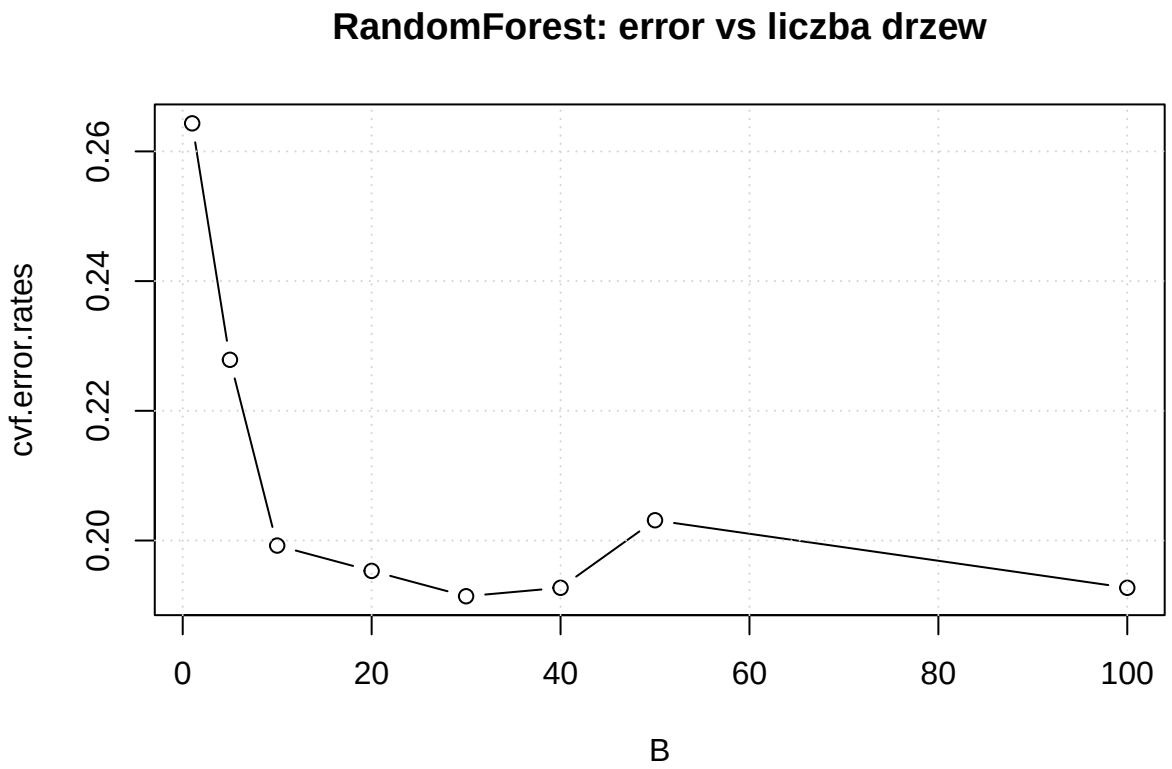

Najmniejszy błąd klasyfikacji dla 100, 30, 20 i 10 drzew. Brak dużych wahań między poziomami wartości błędu, jedynie dla 1 drzewa wynosi on 26%, odstaje od pozostałych.

1.2.3 Ranking cech - wykres VIM

Miara MeanDecreaseAccuracy wskazuje, jak bardzo dokładność modelu spada po usunięciu danej zmiennej — im większa wartość, tym bardziej zmienna jest istotna dla predykcji.

Miara MeanDecreaseGini pokazuje, jak bardzo dana zmienna poprawia czystość podziałów w drzewach — wyższe wartości oznaczają większy wpływ na strukturę drzewa.

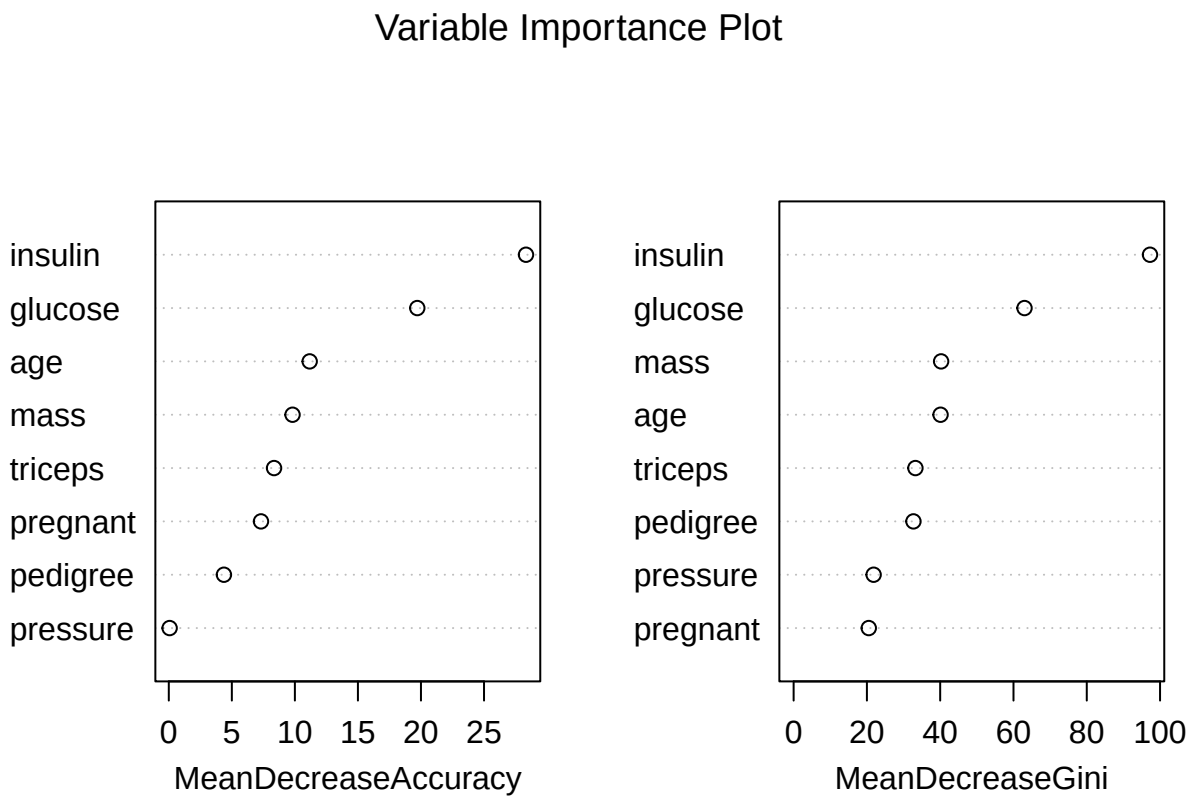

Insulin, glucose mają najwyższe wartości zarówno dla MeanDecreaseAccuracy, jak i MeanDecreaseGini, co oznacza, że jest najistotniejszym czynnikiem wpływającym na klasyfikację cukrzycy w modelu.

Inne zmienne, takie jak mass i age, również mają wysokie wartości ważności, co wskazuje, że znacznie przyczyniają się do poprawy predykcji.

Zmienne takie jak np. pregnant,pressure,pedigree mają niskie wartości obu miar, co sugeruje, że mają niewielki wpływ na działanie modelu i można rozważyć ich pominięcie dla uproszczenia modelu bez utraty dokładności.

Wnioski

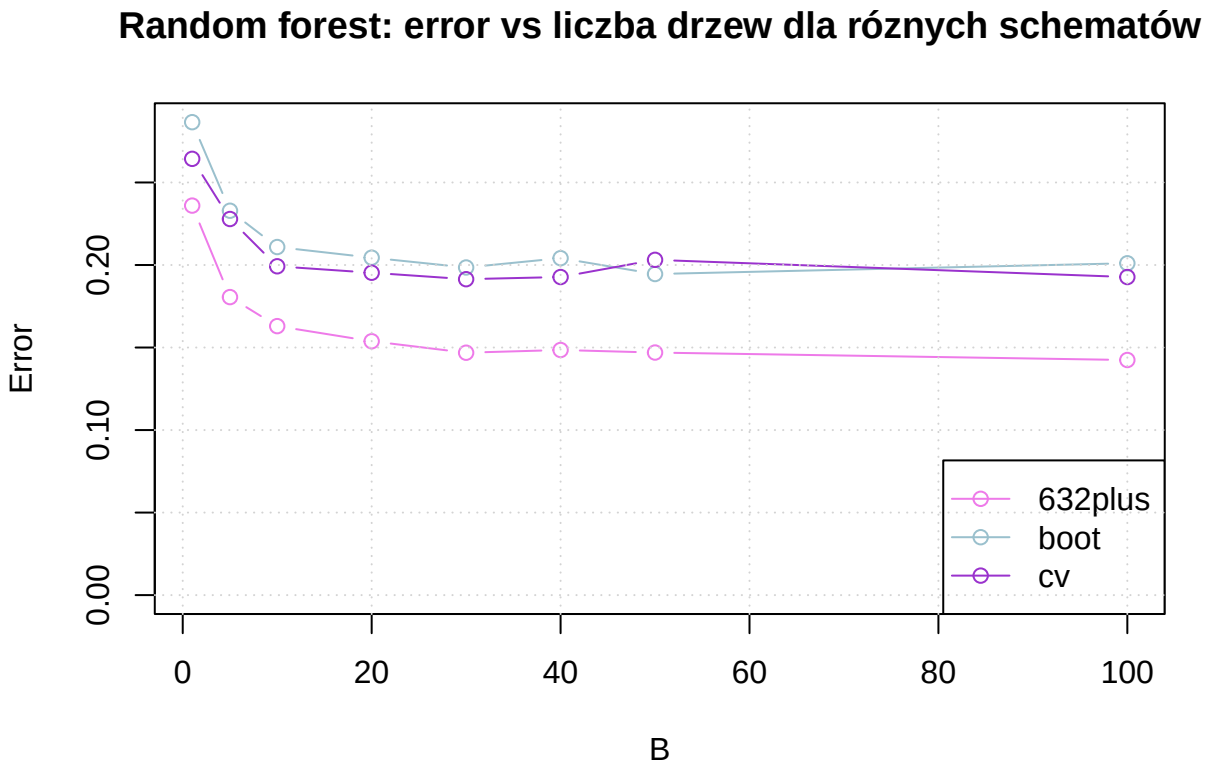

Najmniejsze błędy klasyfikacyjne zwrócił schemat 632+ tak jak w przypadku metody bagging. Różnica błędów klasyfikacyjnych między schematami bootstrap i cross-validation jest bardzo niewielka - 1 odchylenie standardowe.

1.2.4 Wnioski

Pojedyncze drzewo vs metoda bagging

Porównamy poniżej jak przeanalizowane powyżej metody w zależności od schematu sprawdziły się w porównaniu z pojedynczym drzewem.

Schemat "632+"

Tablica 8: Względna redukcja błędu klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Względna redukcja błędu klasyfikacji (w %)
1	1.90
5	14.02
10	17.46
20	22.37
30	21.20
40	20.60
50	22.46
100	22.61

Najwyższą redukcję względną otrzymujemy dla 100 drzew. Duża, zauważalna, największa różnica poprawy

między liczbami drzew następuje między 1 a 5 dzrewami. Między 20 a 100 liczbą drzew różnica w względnej redukcji błędu jest znikoma.

Schemat bootstrap

Tablica 9: Względna redukcja błędu klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Względna redukcja błędu klasyfikacji (w %)
1	-9.70
5	5.33
10	6.12
20	10.02
30	9.86
40	9.49
50	9.94
100	11.86

Dla 1 drzewa nie nastąpiła poprawa. Brak względnej redukcji błedu klasyfikacyjnego. Dużą redukcję względną otrzymujemy dla 20 i 100 drzew.

Schemat cross-validation

Tablica 10: Względna redukcja błędu klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Względna redukcja błędu klasyfikacji (w %)
1	-16.67
5	7.05
10	-7.69
20	7.05
30	-3.21
40	5.77
50	1.28
100	2.56

W przypadku schematu cross-validation redukcja względna błedu jest praktycznie niewidoczna. Pojawia się ona dla 5,20 drzew i wynosi 7.05.

Pojedyncze drzewo vs metoda random forest

Schemat "632+"

Tablica 11: Względna redukcja błędu klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Względna redukcja błędu klasyfikacji (w %)
1	-14.00
5	12.78
10	21.28
20	25.70
30	29.06
40	28.26

Liczba drzew (B)	Względna redukcja błędu klasyfikacji (w %)
50	29.01
100	31.19

Dla 1 drzewa nie otzrymaliśmy redukcji względnej błedu klasyfikacji. Istoną różnice zauważamy już dla 5 drzew. Największą redukcję błędu otrzymujemy dla 100 drzew, nie różni się ona znacząco od wyniku względnej redukcji dla 30,40,50 drzew.

Schemat bootstrap

Tablica 12: Względna redukcja błędu klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Względna redukcja błędu klasyfikacji (w %)
1	-21.75
5	1.05
10	10.39
20	13.13
30	15.66
40	13.26
50	17.34
100	14.57

Brak redukcji błedu dla 1 drzewa. Największą redukcję błędu otrzymaliśmy dla 50 drzew, choć nie rózni się ona znacząco od tej otrzymanej dla 30 drzew. Największą różnicę między względnymi redukcjami błędów notujemy między 1 drzewem a 5.

Schemat cross-validation

Tablica 13: Względna redukcja błędu klasyfikacji w zależności od liczby drzew (B)

Liczba drzew (B)	Względna redukcja błędu klasyfikacji (w %)
1	-30.13
5	-12.18
10	1.92
20	3.85
30	5.77
40	5.13
50	0.00
100	5.13

Brak redukcji błędu dla 1 oraz 5 drzew. Względna redukcja błedu w tym przypadku jest niewielka, nawet dla 50 drzew jest ona równa 0. Dla 100 drzew notujemy względną redukcję błedu na poziomie 5%.

1.3 c) Metoda wektorów nośnych (SVM)

1.3.1 Klasyfikatory dla funkcji jądrowych - porównanie skuteczności

SVM to algorytm klasyfikacji, który poprzez zastosowanie funkcji jądra przekształca dane do wyższej wymiarowości, umożliwiając znalezienie optymalnej liniowej granicy rozdzielającej klasy.

Algorytm SVM

Do algorytmu SVM stosujemy schemat 632+.

Jądro liniowe

Tablica 14: Błąd klasyfikacji metody SVM - jądro liniowe - w zależności od parametru cost

Cost (C)	Błąd klasyfikacji SVM (%)
0.01	22.89
0.10	23.27
1.00	22.76
10.00	22.92

Błędy klasyfikacyjne są na podobnym poziomie niezależnie od paramateru cost - 23%.

Jądro wielomianowe

Wybieram parametr degree = 2

Tablica 15: Błąd klasyfikacji metody SVM - jądro wielomianowe - w zależności od parametru cost

Cost (C)	Błąd klasyfikacji SVM (%)
0.01	34.90
0.10	34.24
1.00	30.87
10.00	30.47

Większy błąd klasyfikacyjny otrzymujemy dla parametru cost 0.01 oraz 0.1 - 34%, prawie 35%. Dla 1.0 oraz 10 wartości cost błąd jest na poziomie 31%.

Wybieram parametr degree = 4

Tablica 16: Błąd klasyfikacji metody SVM - jądro wielomianowe - w zależności od parametru cost

Cost (C)	Błąd klasyfikacji SVM (%)
0.01	33.60
0.10	30.64
1.00	28.26
10.00	29.67

Dla tego parametru notujemy mniejsze błedy klasyfikacyjne. Najmniejszy dla cost=10 30%, a największy na poziomie 33% dla cot=0.01. Różnice między cost=0.1 a cost=10 nie są znaczące.

Jądro radialne

Wybieram parametr gamma =0.1

Tablica 17: Błąd klasyfikacji metody SVM - jądro radialne - w zależności od parametru cost

Cost (C)	Błąd klasyfikacji SVM (%)
0.01	34.90
0.10	22.94
1.00	21.50
10.00	20.76

Dla parametru cost=0.01 otrzymujemy błąd klasyfikacji na poziomie 35%. Mniejszy błąd zauważamy dla cost=10 i wynosi on 21%. Dla cost=1 oraz cost=0.1 błedy wahają się na poziomie 21%-22%.

Wybieram parametr gamma = 1

Tablica 18: Błąd klasyfikacji metody SVM - jądro radialne - w zależności od parametru cost

Cost (C)	Błąd klasyfikacji SVM (%)
0.01	34.90
0.10	34.90
1.00	21.61
10.00	21.95

Większy błąd klasyfikacyjny otrzymujemy dla parametru cost 0.01 oraz 0.1 - 35%. Dla 1.0 oraz 10 wartości cost błąd jest na poziomie 21%.

Wnioski

Prównuje metody dla parametrów dla gamma 0.1 i degree=2, ponieważ dla nich w konkretnych metodach błędy klasyfikacyjne były niższe.

Najmniejsze błędy klasyfikacji otrzymuejmy dla radialnego jądra dla wyższych parametrów cost.

1.3.2 "Dostrojenie" parametrów γ i C dla jądra radialnego

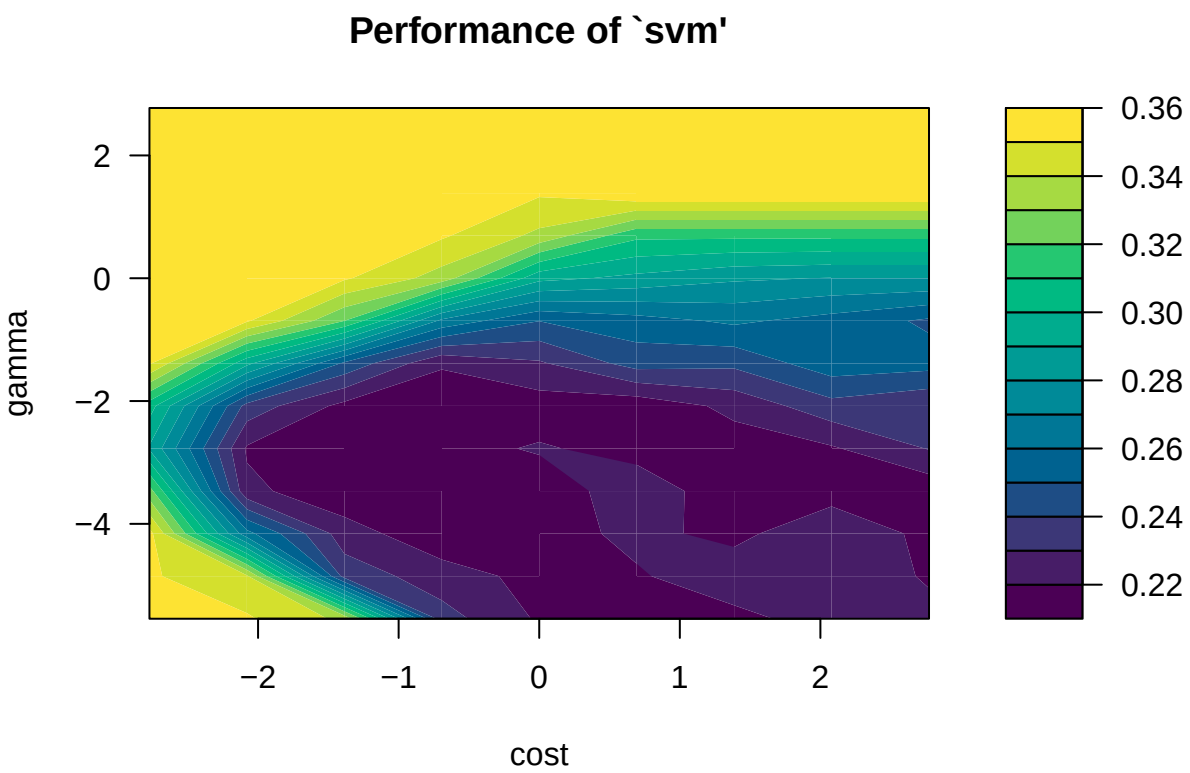

Najlepszy dobór parametrów taki, aby błąd klasyfikacji był najmniejszy znajdziemy, gdy na powyższyzm wykresie wypatrzymy kolor ciemno-granatowy. To znaczy im wyższe cost (powyżej -1) i mniejsze gamma tym lepiej.

γ= 0.015625

C= 0.5

Błąd klasyfikacyjny dla tych parametrów jest na poziomie 22.47%

Porównanie modelów jądra radialnego dla wyznaczonych optymalnych parametrów

Tablica 19: Porównanie modelów jądra radialnego dla wyznaczonych optymalnych parametrów

cost	gamma	błąd
0.50	0.0156	22.47%
0.01	0.1000	34.9%
0.10	0.1000	22.94%
1.00	0.1000	21.5%
10.00	0.1000	20.76%

Wnioski

Optymalne parametry cost i gamma nie okazały się najlepsze. Mniejszy błąd klasyfikacyjny otrzymujemy dla cost=10 oraz gamma=0.1. Różnica między nimi wynosi 3 punkty procentowe. Najgorzej wypadł układ paramterów cost=0.01 i gamma 0.1, błąd wynosi 34.9%.

1.3.3 Wnioski

Różnica między wynikami poszczególnych jąder przedstawia się następująco:

Między jądrem liniowym a wielomianowym różnica błedu klasyfikacji jest na poziomie 8 punktów procentowych, między liniowym i radialnym na poziomie w zależności od parameteru cost, gamma 2-8 punktów procentowych, między radialnym, a wielomianowym w zależności od parametrów gamma, cost, degree ta różnica waha się na poziomie 1-12 punktów precentowych.

Większe błedy klasyfikacyjne otrzymaliśmy dla jądra wielomiaonwego, małe wartości błedu otzrymaliśmy dla jądra liniowego. Małą wartość błedu otrzymaliśmy również dla jądra radialnego dla parametrów gamma=0.1 i cost=10.

1.4 d) Wnioski - porównanie skuteczności metod na podstawie podpunktu b, c

Podsumowując z pośród rozważanych metod najmniejszy błąd klasyfikacyjny wskazały metody bagging 16%-20%, randomforest na poziomie 20.5% (w zależności od schemtu), oraz jądro radialne dla parametru gamma=0.1 i cost=10 20.7%.

Przeważnie im więcej drzew tym mniejszy błąd klasyfikacji dla metod bagging, random forest.

Pojedyńcze drzewo klasyfikowało na poziomie 21%-23%.

Metoda random forest miała większe względne redukcje błędów.

Zatem najlepszą skuteczność wykazała metoda bagging, randomforest oraz SVM-jądro radialne.